



- **1** Slipstream基础
- 2 StreamSQL DDL
- **3** StreamSQL DML
- 4 事件驱动的流处理
- 5 实战案例



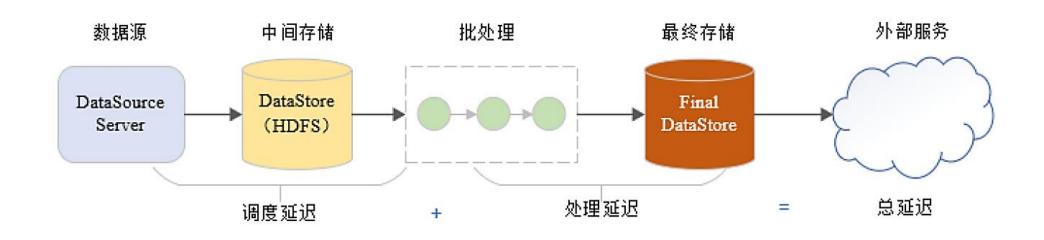
1.1 背景介绍

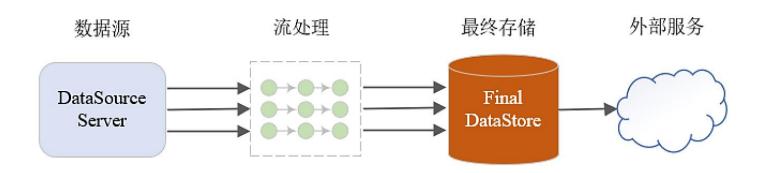
▶ 批处理

- 批量处理
- 调度延时
- 处理延时

> 流处理

- 流式处理
- 低延时

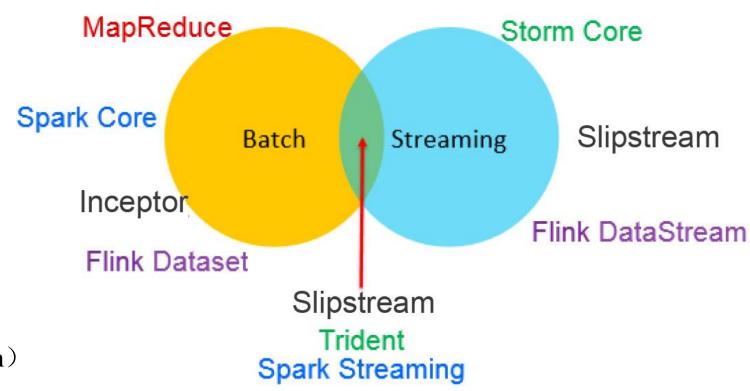






1.1 背景介绍

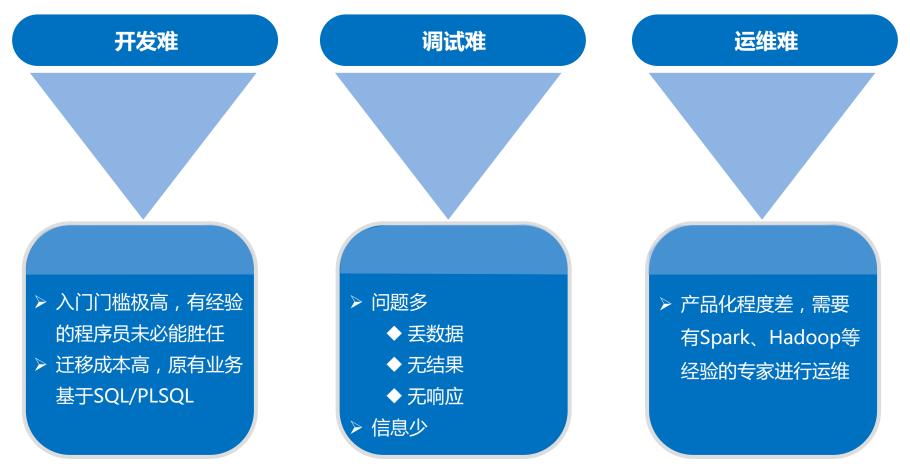
- > 批处理计算框架
 - MapReduce
 - Spark Core
 - Inceptor
 - Flink Dataset
- > 流式计算框架
 - 基于事件驱动
 - Storm Core
 - Slipstream
 - Flink DataStream
 - 基于微型批处理(Micro-batch)
 - Spark Streaming
 - Slipstream
 - Storm Trident





1.1 背景介绍

> 流式计算框架存在的问题





1.2 Slipstream简介

▶ 定位

- 融合事件驱动与微批处理的实时流计算引擎
- 分布式流式SQL引擎

▶ 特点

- 微批模式和事件驱动模式的一体化
 - 两种流处理模式可从容应对不同延时级别的业务场景,微批→秒级,事件驱动→毫秒级
 - 在同一套系统里,可以根据业务需求,通过参数配置和SQL改写,灵活切换两种流处理模式
- 支持分布式流式SQL(StreamSQL)
 - 支持99%的ANSI SQL 2003, 95%的PL/SQL Oracle与PL/SQL DB2
 - 支持通过SQL创建并操作流,并支持在流上做存储过程等复杂逻辑处理
 - 降低流应用开发门槛,提高流应用开发效率
 - 帮助用户低成本将传统业务逻辑变成流应用



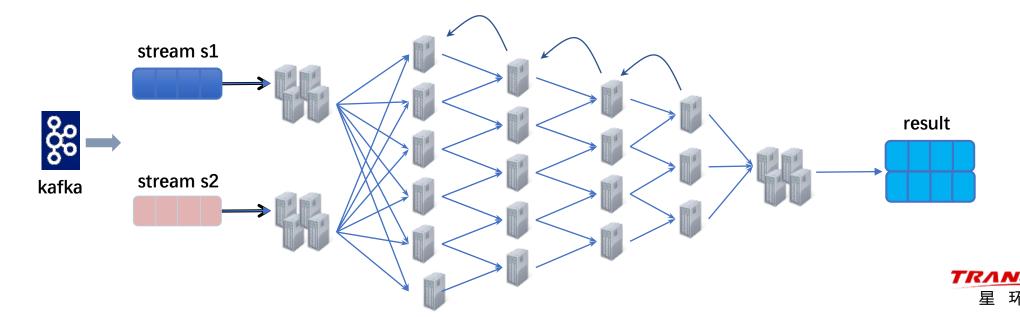
1.2 Slipstream简介

▶ 特点

- 强大的优化器提升性能
 - 包含3级优化器: 基于规则的优化器、基于代价的优化器、代码生成器
 - 在一些条件下,采用StreamSQL可以获得比编程方式更高的性能,因为Slipstream做了特殊优化,编程 无法轻易实现,例如:增加迭代框架
- 极高的易用性
 - 只要有编写普通SQL的经验,就可以写出高效、稳定、安全的流处理应用
- 产品化程度高
 - StreamSQL作为一个通用的接口显著提升了产品化程度
- 迁移成本低
 - 用户原有的业务逻辑很多是通过SQL实现的,系统迁移时只需修改SQL,迁移成本大大降低

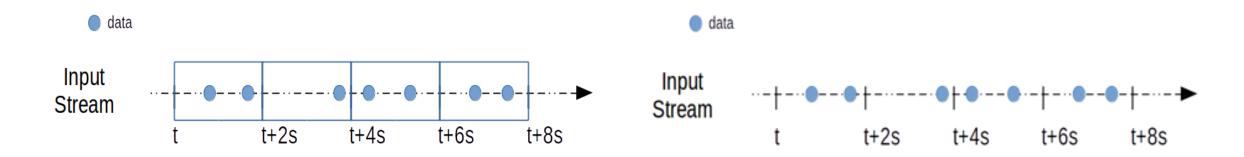


- ➤ Slipstream的三个核心概念
 - Stream (数据流)
 - StreamJob (流任务)
 - 对一个或多个Stream进行计算,并将结果写入一张表的任务
 - Application (流应用)
 - -一组业务逻辑相关的StreamJob的集合



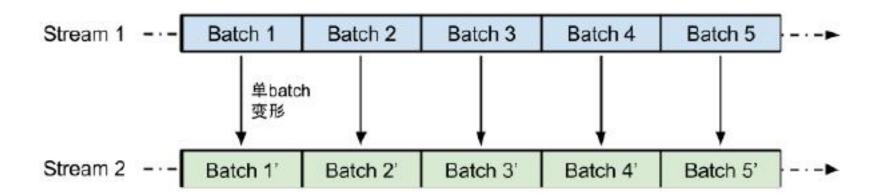
➤ Stream (数据流)

- Input Stream (输入流)
 - 定义: 直接接收数据源传来的数据而形成的Stream
 - 功能: 定义了如何从数据源读取数据,如: Kafka、Socket
 - 微批(Micro-batch)模式:将Input Stream按时间划分成若干小数据块(Batch)来处理,即在由若干单位时间组成的时间间隔内,将接收的数据放到一个Batch中(Batch的时间长度称为Batch Duration)
 - 事件驱动(Event-driven)模式:以单条数据被Input Stream接收为事件,逐条读取并处理





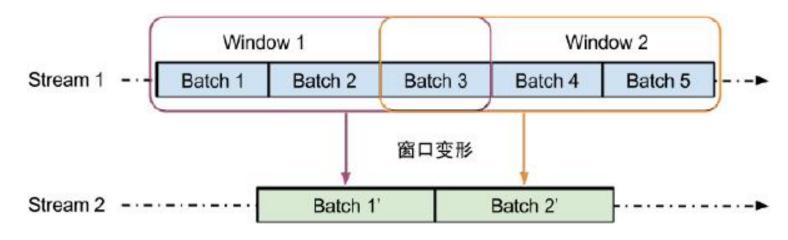
- ➤ Stream (数据流)
 - Derived Stream (衍生流)
 - Derived Stream由StreamSQL语句对已有的Stream变形(Transform)得来
 - Stream变形通常由CSAS(Create Stream As Select)语句完成
 - 微批模式
 - ①含义: Stream变形是从已有Batch计算得到新Batch的过程
 - ②单Batch变形:对Stream中单个Batch进行计算得到新Batch的过程



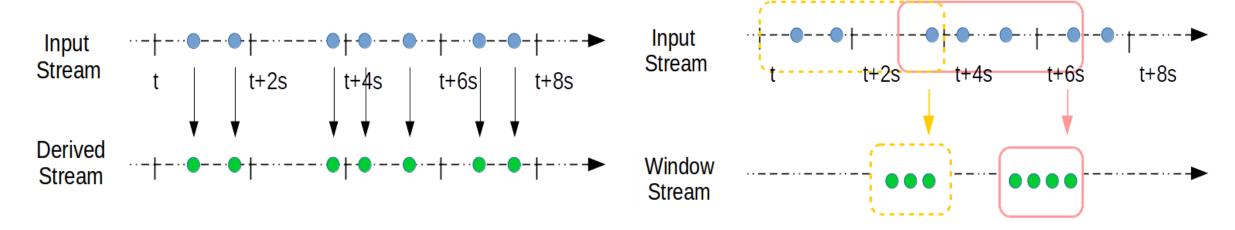


- ➤ Stream (数据流)
 - Derived Stream (衍生流)
 - 微批模式
 - ③窗口变形(多Batch变形)
 - *对一个时间窗口(Window)内的多个Batch进行计算得到新Batch的过程
 - *Window Stream: 通过窗口变形得到的Derived Stream
 - *两个重要参数: Length和Slide, Length是窗口持续时间, Slide是两个相邻窗口之间的间隔时间,

Length和Slide必须是Batch Duration的倍数



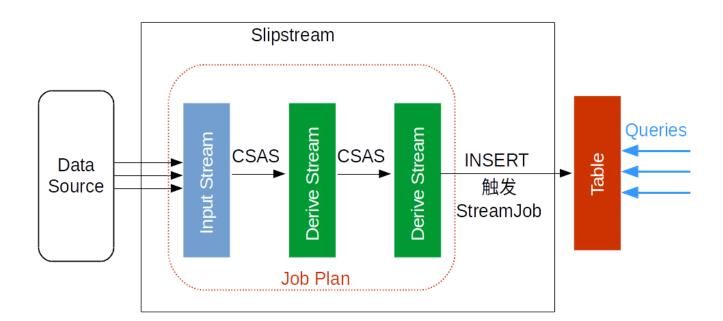
- ➤ Stream (数据流)
 - Derived Stream (衍生流)
 - 事件驱动模式
 - ①含义:每得到一条数据就对其进行变形,得到Derived Stream
 - ②单数据变形:对Stream中单条数据进行计算得到新数据的过程
 - ③窗口变形(多数据变形):对一个时间窗口(Window)内的多条数据进行计算得到新数据的过程





➤ StreamJob (流任务)

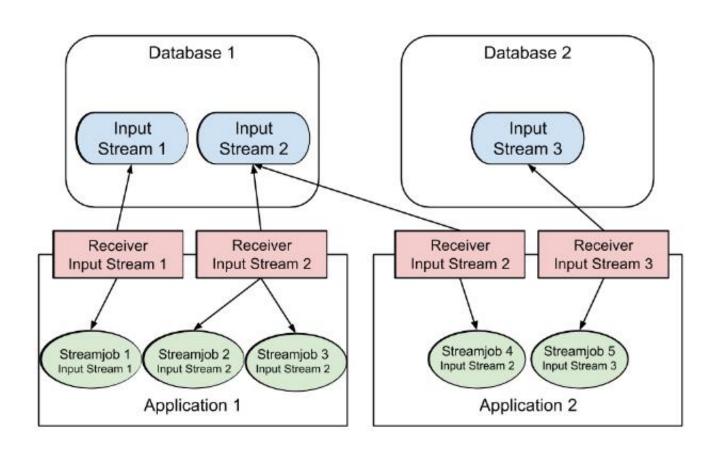
- StreamSQL中的Stream是静态的,它仅仅描述了如何对数据源传来的数据进行接收和变形的 计划,但并不执行这些计划
- 要让StreamSQL执行计划,需要有相应的Action操作来触发StreamJob
- 一个StreamJob启动时,StreamSQL会为每一个Input Stream启动一组称为Receiver的任务来接收数据,接收来的数据经过一系列Derived Stream的变形最终被插入一张表,供用户查询





➤ Application (流应用)

- Application是一组业务逻辑相关的 StreamJob集合
- 合理使用Application划分StreamJob可以实现资源的共享和隔离
 - 资源共享: Application内使用同一个Input Stream的StreamJob共享一组Receiver
 - 资源隔离:不同Application中的StreamJob 若使用同一个Input Stream,则每个 Application都为这个InputStream启动一组 Receiver





1.4 StreamSQL vs. 普通SQL

➤ DML语句的运行机制不同

- 普通SQL: 阻塞式运行
 - 提交SQL后,用户需等待SQL执行结束,期间命令被持续阻塞,无法执行其他命令
- StreamSQL: 背景运行
 - 计算任务持续在后台运行
 - 执行StreamSQL的DML语句会立即返回结果

> 查询结果的输出不同

- 普通SQL: 查询结果或者显示在Console, 或者通过JDBC读取
- StreamSQL: 用户必须显式地指定查询结果输出到某个地方
 - 后台持续运行的SQL无法直接跟Console交互
 - 查询结果通常会插入到表中,如: Insert Into result_table Select ...





2.1 Stream管理

➤ Stream管理操作

• Create Stream: 创建Input Stream

• Create Stream As Select: 创建Derived Stream

• Show Streams: 列出所有的Stream

• Describe Stream: 查看Stream信息

• Alter Stream: 修改Input Stream

• Drop Stream: 删除Input Stream



➤ 创建Input Stream:完整语法

```
CREATE STREAM <stream_name>(<col_name> <data_type>, <col_name> <data_type>, ...)
  [ROW FORMAT DELIMITED FIELDS TERMINATED BY '<delimiter1>'
    COLLECTION ITEMS TERMINATED BY '<delimiter2>'
    MAP KEYS TERMINATED BY '<delimiter3>' ] ①
  TBLPROPERTIES(["topic"="<topic name>",] 2
    ["source"="kafka",] ③
    ["kafka.zookeeper"="<ip:port>",] 4
    ["kafka.broker.list"="<ip:port>",] ⑤
    ["partitions"="<int>,<int>, ...",] (6)
    ["transwarp.consumer.security.protocol"="rotocol>",] ⑦
    ["transwarp.consumer.sasl.kerberos.service.name"="service_name",] ⑦
    ["transwarp.consumer.sasl.jaas.config"="jass_string",] ⑦
    ["batchduration"="<int>",] (8)
    ["<key>"="<value>",] 9
    ["transwarp.consumer.<property_key>"="kafka_consumer_property_value",] ①
    ["transwarp.producer.<property_key>"="kafka_producer_property_value",] (11)
```



➤ 创建Input Stream:完整语法

- ① <delimiterN>指定数据字段间的分隔符,对于简单类型默认是","。
- ② <topic_name>指定Input Stream指向的Kafka Topic,默认值是database_name.table_name。
- ③ <source>指定数据源来源,默认为Kafka。
- ④ <ip:port>指定TDH集群中的一个Zookeeper节点的ip和端口号,除非另外设置,Zookeeper的端口号为2181,默认为当前集群的ZK的地址和端口号。建议在创建Stream时设置此项。
- ⑤ <ip:port>指定集群中的任意一个Kafka Broker的ip和端口号,默认为9092。
- ⑥ 可选项。从Topic中指定的Partition上获取流数据。注意,指定Partition属性时,需要同时指定kafka.broker.list属性。
- ⑦这三个选项在安全模式下以Kafka为源时需要使用,细节参考安全模式。
- ⑧ 设置Batch的长度,整数,单位为毫秒。该属性只能在事件时间模式下使用,且只对微批模式的流处理适用。

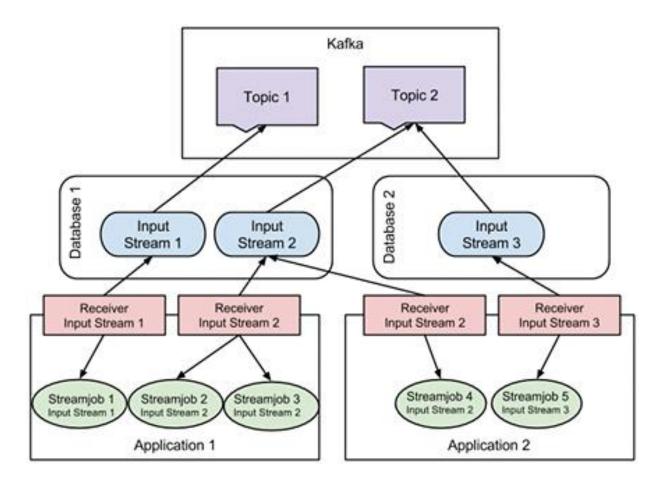


➤ 创建Input Stream:完整语法

- ⑨ TBLPROPERTIES中还可以包含任意自定义的键值对,用于存放用户自定义的流属性。
- ⑩ 指定StreamJob启动Kafka Consumer使用的属性值。property_key为Kafka Consumer所支持的某个配置属性名,例如,想配置Consumer能接收的消息的大小,可指定"transwarp.consumer.fetch.max.bytes"="1000000"。
- ① 当Stream作为输出流时,可通过此配置项来设定StreamJob启动Kafka Producer时使用的属性值。property_key为Kafka producer所支持的某个配置属性名,例如,想配置Producer发送消息的ack模式,可指定"transwarp.producer.acks"="0"。



- ➤ 创建Input Stream:数据源为Kafka
 - 发布给Kafka Topic的消息通过Input Stream进入Slipstream
 - 一个Input Stream只能接收一个Topic中的消息,多个Input Stream可以指向同一个Topic





- ➤ 创建Input Stream:数据源为Kafka
 - 创建从指定Topic中接收数据的Stream

```
CREATE STREAM demo(id INT, letter STRING) ROW FORMAT DELIMITED FIELDS TERMINATED BY ','

TBLPROPERTIES(

"topic" = "demo",

"kafka.zookeeper" = "172.16.1.128:2181",

"kafka.broker.list" = "172.16.1.128:9092"

);
```

• 创建从指定Partition中接收数据的Stream

```
CREATE STREAM demo(id INT, letter STRING) ROW FORMAT DELIMITED FIELDS TERMINATED BY ','

TBLPROPERTIES(

"topic" = "demo",

"partitions" = "0,3",

"kafka.zookeeper" = "172.16.1.128:2181",

"kafka.broker.list" = "172.16.1.128:9092"

);
```

➤ 创建Input Stream:数据源为Socket

```
CREATE STREAM socket_stream(id INT, name STRING, sex BOOLEAN)

TBLPROPERTIES(

"source" = "socket",

"host" = "172.16.1.182",

"port" = "8888"

);
```

➤ 创建Input Stream:复杂类型Struct

```
/* Kafka数据格式: 1,5|five 2,9|nine */
CREATE STREAM struct_stream (id INT, s1 STRUCT<a:INT, b:STRING>)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
COLLECTION ITEMS TERMINATED BY '|';
```



➤ 创建Input Stream:复杂类型Array

```
/* Kafka数据格式: 1,1|2|3|4 2,2|4|6|8*/
CREATE STREAM array_stream (id INT, a1 ARRAY<STRING>)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
COLLECTION ITEMS TERMINATED BY '|';
```

➤ 创建Input Stream:复杂类型Map

```
/* Kafka数据格式: 1,job:800|team:60 2,job:60|team:80 */
CREATE STREAM map_stream (id INT, m1 MAP<STRING,INT>)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
COLLECTION ITEMS TERMINATED BY '|' MAP KEYS TERMINATED BY ':';
```

➤ 创建Input Stream:复杂类型Timestamp

```
/* Timestamp默认格式: yyyy-MM-dd HH:mm:SS
Kafka数据格式: 1,2015-01-15 00:16:10 2,2077-11-15 23:16:10 */
CREATE STREAM student_stream (id INT, t1 TIMESTAMP);
```

2.1 Stream管理

- ➤ 创建Derived Stream:数据源为Stream
 - 使用已有的Stream创建Derived Stream

```
CREATE STREAM <stream_name> AS SELECT <select_statement>;

/* Filter变换 */

CREATE STREAM female_name_stream AS SELECT name FROM employee_stream

WHERE sex=true;

/* Window变换 */

CREATE STREAM employee_window_stream AS SELECT * FROM employee_stream

STREAMWINDOW w1 AS(length '12' second slide '4' second);
```

➤ 列出所有Stream与查看Stream信息

```
SHOW STREAMS;
DESCRIBE | DESC [EXTENDED | FORMATTED] STREAM <stream_name>
```

➤ 修改Input Stream: 重命名

ALTER STREAM <old_name> RENAME TO <new_name>;



2.1 Stream管理

➤ 修改Input Stream:修改属性

```
/* 修改任意流属性,包括Kafka Topic、Zookeeper、Broker List,以及自定义流属性 */
ALTER STREAM <stream_name> SET TBLPROPERTIES ("key"="value");
```

➤ 修改Input Stream: 增加列

```
ALTER STREAM <stream_name> ADD COLUMNS(name type[, name1 type1 ...]);
```

➤ 修改Input Stream:替换列

```
ALTER STREAM <stream_name> REPLACE COLUMNS(name type[, name1 type1 ...]);
```

➤ 删除Input Stream

```
DROP STREAM <stream name>;
```



2.2 StreamJob管理

- ➤ StreamJob是触发StreamSQL执行的Action, 一般具有插入结果表语义
- ➤ StreamJob主要存储StreamJob Level的配置参数,以及对应的SQL
- ➤ StreamJob管理操作
 - Create StreamJob: 创建StreamJob
 - Show StreamJobs: 列出所有持久化的StreamJob
 - Describe StreamJob: 查看StreamJob信息
 - Alter StreamJob: 修改StreamJob
 - Drop StreamJob: 删除StreamJob



➤ 创建StreamJob

```
/* <sql_action>为具有Action语义的SQL语句 */
CREATE STREAMJOB <streamjob_name> AS ("<sql_action>")
JOBPROPERTIES(["key"="value"][,"key"="value"...]);
```

➤ 查看StreamJob信息

DESCRIBE|DESC STREAMJOB <streamjob_name>;

➤ 列出所有持久化的StreamJob

SHOW STREAMJOBS;

➤ 修改StreamJob

ALTER STREAMJOB <streamjob_name> SET APPPROPERTIES("key"="value");

➤删除StreamJob

科 技

➤ StreamJob运行时管理

• StreamJob作为StreamSQL运行时的基本单元,也是实时监控的基本单元

```
/* 启动当前Application下的所有StreamJob */
START STREAMJOBS;
/* 启动当前Application下的某个StreamJob */
START STREAMJOB <s1>;
/* 查看当前Application下的所有StreamJob */
LIST STREAMJOBS;
/* 查看当前Application下的某个StreamJob的详细信息 */
LIST STREAMJOB <sid>;
/* 停止当前Application下的所有StreamJob */
STOP STREAMJOBS;
/* 停止当前Application下的某个StreamJob */
STOP STREAMJOB <s1>;
```

2.3 Application管理

- ➤ Application主要用于运行时的隔离和权限验证,在静态时只是一个逻辑概念,一般只用于参数配置
- ➤ 在测试时,用户登录Shell(如Beeline),在自己建的Application下编写业务逻辑
- ▶ 当业务需要上线时,可以用一个Prod Id,具有严格的权限控制,并对应一个Application,将自己的SQL脚本在对应的Application下启动就可以
- ➤ Application管理操作
 - Create Application: 创建Application
 - Show Applications: 列出所有Application
 - Describe Application: 查看Application信息
 - Alter Application: 修改Application
 - Drop Application: 删除Application



▶ 创建Applicaiton

```
CREATE APPLICATION <app_name>
WITH APPPROPERTIES(["key"="value"][,"key"="value"...]);
```

➤ 查看Applicaiton信息

```
DESCRIBE | DESC APPLICATION <app_name>;
```

➤ 列出所有Applicaiton

```
SHOW APPLICATIONS;
```

➤ 修改Applicaiton

```
ALTER APPLICATION <app_name> SET APPPROPERTIES("key"="value");
```

➤ 删除Applicaiton

DROP APPLICATION <app_name>;

2.3 Application管理

➤ Applicaiton运行时管理

- 用户运行任何StreamJob之前需要进入对应的Application
- •默认情况下,当前的Application是Default

```
/* 进入Application */
USE APPLICATION app1;
/* 显示正在运行的Application */
LIST APPLICATIONS;
```





- ▶ 流应用通常会对一个窗口(时间间隔)内的数据做多表关联、聚合或统计
- > 非窗口计算
 - 默认以系统时间为基准,每隔一段时间(微批)或每产生一条数据(事件)触发一次计算
- ▶ 窗口计算:时间作为窗口切分单位
 - 事件时间切分: 在SQL中指定数据流中的某个时间字段,以该时间字段为基准切分窗口
 - 系统时间切分: 在SQL中不指定时间字段, 以系统时间为基准切分窗口

▶ 窗口类型

- 滑动窗口
 - 定义: 按一定时间间隔向未来滑动的长度固定的窗口
 - -特点:前后窗口之间有重叠
 - 示例:对于窗口长度为2s,滑动间隔为1s的滑动窗口,[0s,2s)为第一个窗口,[1s,3s)为第二个窗口,[2s,4s)为第三个窗口,依次类推



> 窗口类型

- 滑动窗口
 - 特例:无限滑动窗口,即按照滑动间隔,每滑动一次触发一次计算,但每次计算都包括所有以前窗口的计算值,例如:统计网页访问次数,每隔一段时间输出当时的累计值
- 跳动窗口
 - 定义: 当窗口长度和滑动间隔相同,滑动窗口就退化为跳动窗口
 - -特点:前后窗口之间无重叠,跳动窗口是滑动窗口Length = Slide的特例
 - 示例:以2s为间隔的跳动窗口,[0s,2s)为第一个区间,[2s,4s)为第二个区间,依次类推

▶ 窗口切分方式

• 系统时间切分: 以流处理引擎的系统时间为基准切分窗口

CREATE STREAM s1(id INT, name STRING, ts TIMESTAMP);
INSERT INTO t1 SELECT * FROM s1 STREAMWINDOW w1 AS(LENGTH '2' SECOND SLIDE '1' SECOND);



▶ 窗口切分方式

• 事件时间切分: 以数据流中的指定时间字段为基准切分窗口

```
/* 以时间字段ts为基准切分窗口,窗口宽度为2秒,滑动间隔为1秒 */
SET streamsql.use.eventtime=true;
CREATE STREAM s1(id INT, name STRING, ts TIMESTAMP)
tblproperties("timefield"="ts");
INSERT INTO t1 SELECT * FROM s1 STREAMWINDOW w1 AS(LENGTH '2' SECOND SLIDE '1' SECOND);
```

• 事件时间切分: 自定义时间格式(默认时间格式为yyyy-MM-dd HH:mm:ss)

```
/* 以时间字段ts为基准切分窗口,窗口宽度为2分钟,滑动间隔为1分钟,
指定格式为 "yyyy-MM-dd HH:mm",不包含秒级信息 */
CREATE STREAM s1(id INT, name STRING, ts TIMESTAMP)
TBLPROPERTIES("timefield"="ts", "timeformat"="yyyy-MM-dd HH:mm");
INSERT INTO t1 SELECT * FROM s1 STREAMWINDOW w1 AS(LENGTH '2' MINUTE SLIDE '1' MINUTE);
```



▶ 窗口切分方式

• 事件时间切分: 支持String类型

CREATE STREAM s1(id INT, name STRING, ts STRING)

TBLPROPERTIES("timefield"="ts","timeformat"="MM/dd/yyyy HH:mm:ss");

- 事件时间切分与系统时间切分的区别
 - 默认的窗口切分方式为系统时间
 - 优先级: 前者高于后者
 - 灵活性: 前者更灵活,不同窗口可以指定不同的时间字段
 - 格式支持: 前者可以满足多种时间格式



- ▶ 输出到流
 - StreamSQL支持将查询结果输出到另一个流
 - 方式一: 将一个流原样输出到另一个流

```
CREATE STREAM s1(id INT, name STRING);
CREATE STREAM s2(id INT, name STRING);
INSERT INTO s2 SELECT * FROM s1;
```

• 方式二: 将一个流变换为另一个流

```
/* Filter变换 */
CREATE STREAM female_name_stream
    AS SELECT name FROM employee_stream WHERE sex==true;
/* Window变换 */
CREATE STREAM employee_window_stream
    AS SELECT * FROM employee_stream
    STREAMWINDOW w1 AS(LENGTH '12' SECOND SLIDE '4' SECOND);
```

➤ 输出到Hyperbase

```
/* 创建输入流 */
CREATE STREAM employee stream(id INT, name STRING, sex BOOLEAN);
/* 创建Hyperbase表 */
CREATE TABLE hyper(row_key data_type, col_name1 data_type, col_name2, data_type, ...)
 STORED BY 'org.apache.hadoop.hive.hbase.HBaseStorageHandler|
    io.transwarp.hyperbase.HyperbaseStorageHandler'
    WITH SERDEPROPERTIES("hbase.columns.mapping"=":row key column,
    column family:column qualifer 1, column family:column qualifier 2, ...")
 TBLPROPERTIES ("hbase.table.name" = "hbase table name");
/*将流转换后插入Hyperbase表 */
INSERT INTO hyper SELECT * FROM employee stream WHERE sex=true;
```



➤ 输出到Kafka

```
/* 创建两个Kafka Topic输入流 */
CREATE STREAM s1(id INT, letter STRING)
  ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
  TBLPROPERTIES(
    "topic"="s1",
    "kafka.zookeeper"="172.16.1.128:2181");
CREATE STREAM s2(id INT, letter STRING)
  ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
  TBLPROPERTIES(
    "topic"="s2",
    "kafka.zookeeper"="172.16.1.128:2181");
/* 将s1输出到s2 */
INSERT INTO s2 SELECT * FROM s1;
```



▶含义

- •以单条数据被Input Stream接收为事件,逐条读取数据,并立刻加工处理,最后输出
- 来一条处理一条

▶ 特点

•相比微批模式(TDH 4.8之前),事件驱动模式的延迟更低,在延迟敏感的场景中表现更佳

> 开启事件驱动模式

- •第一步: 让Slipstream引擎运行在事件驱动模式下
 - 在Transwarp Manager中配置系统参数: NGMR_ENGINE_MODE = morphling
 - morphling代表事件驱动模式(TDH 5.1之后的默认值),mapred代表微批(TDH 5.1之前的默认值)
- 第二步: 让StreamJob运行在事件驱动模式下
 - TDH 5.1之前,在启动StreamJob之前,配置Job参数: streamsql.use.eventmode = true
 - -TDH 5.1之后,如果当前引擎是morphling,则默认开启该参数,否则默认关闭



➤ 将流表中的数据写入Inceptor普通表

```
/* 开启Job的事件驱动模式 */
SET streamsql.use.eventmode=true;
/* 创建Kafka输入流 */
CREATE STREAM s1(score INT, name STRING)
  TBLPROPERTIES(
    "topic"="tps1",
    "kafka.zookeeper"="172.16.1.128:2181",
    "kafka.broker.list"="172.16.1.128:9092");
/* 创建Inceptor表 */
CREATE TABLE t1(score INT, name STRING);
/* 将流表中的数据写入Inceptor表 */
INSERT INTO t1 SELECT * FROM s1;
```



➤ 在Window Stream上做聚合后写入Inceptor普通表

```
/* 开启Job的事件驱动模式 */
SET streamsql.use.eventmode=true;
/* 开启窗口的事件时间切分模式 */
SET streamsql.use.eventtime=true;
/* 创建Window Stream */
CREATE STREAM s1(name STRING, score INT, ts STRING)
  TBLPROPERTIES("topic"="tps1",
    "kafka.zookeeper"="tw-node127:2181",
    "kafka.broker.list"="tw-node127:9092",
   "timefield"="ts",
    "timeformat"="yyyy-MM-dd HH:mm:ss",
    "use.lowlevel.consumer"="true");
CREATE STREAM ws1 AS SELECCT * FROM s1 STREAMWINDOW (LENGTH '4' SECOND SLIDE '2' SECOND);
/* 先对Window Stream做聚合,再写入Inceptor表 */
CREATE TABLE t1(score INT, name STRING);
INSERT INTO t1 SELECT name, SUM(score) FROM ws1 GROUP BY name;
```



> 业务需求

• 为了及时了解商品热度,某电商管理者希望对网站商品的访问量进行统计分析,统计范围为过去5分钟,并以1分钟为周期进行持续更新

> 样例数据

• 前端实时收集的数据

/* 数据格式:访问者IP,访问的商品网页,访问时间*/

27.0.1.125,www.taobao.com/xx1.html,2016-8-14 20:43:31.213

72.21.203.5, www.taobao.com/xx2.html, 2016-8-14 20:45:31.132

207.241.224.2,www.taobao.com/xx3.html,2016-8-14 20:46:15.540

12.129.206.133,www.taobao.com/xx3.html,2016-8-14 20:47:21.332

208.111.148.7,www.taobao.com/xx1.html,2016-8-14 20:50:31.876



> 解决方法

• Step1: 通过Kafka消息队列收集数据

```
# ./kafka-topics.sh –create
--zookeeper tdh-71:2181,tdh-72:2181,tdh-73:2181
--topic accesslog --partition 3 --replication-factor 1
```

• Step2: 创建以Kafka为数据源的Input Stream

```
CREATE STREAM accesslog (
ip STRING,
url STRING,
time TIMESTAMP)
ROW FORMAT delimited FIELDS TERMINATED BY ','
TBLPROPERTIES(
"topic" = "accesslog",
"kafka.zookeeper"="tdh-71:2181,tdh-72:2181,tdh-73:2181",
"kafka.broker.list"="tdh-71:9092,tdh-72:9092,tdh-73:9092");
```

> 解决方法

• Step3: 根据业务创建长度为5min,滑动步长为1min的时间窗口

CREATE STREAM waccesslog AS

SELECT * FROM accesslog STREAMWINDOW sw AS (LENGTH '5' MINUTE SLIDE '1' MINUTE);

• Step4: 创建结果表来存储流处理后的数据

CREATE TABLE result(rowkey STRING, url STRING, count INT) STORED AS HYPERDRIVE;

• Step5: 创建StreamJob, 定义并启动流处理任务

CREATE STREAMJOB hotcount AS (
"INSERT INTO result SELECT uniq(), url, COUNT(*) FROM waccesslog GROUP BY url");
START STREAMJOB hotcount;



